

# 基于 RK3588 的智能交互仿生人头,实现多模态感知 与实时动作响应

## 摘要

当优必选发布会上说“年轻人可以不结婚，机器人陪你”引发舆论风波时，争议核心在于——技术应弥补情感缺失，而非替代人际关系。本作品正是如此：不做伴侣机器人，而是聚焦心理开导与情感陪护，为独居青年、空巢老人提供有温度的智能助手与心理宣泄口，突破“恐怖谷效应”，赋予机器人自然的表情表达与人机共情能力。

自然交互是高噪声、不完整的一一用户说“没事”可能并非没事，沉默也是需要被理解的反馈。仿生机器人要做的不是机械的多轮对话，而是从语言、表情、场景中还原真实需求。本作品搭载的心理垂域大模型能从交互中理解用户潜在意图，判断该安抚还是推进、该主动还是等待。

本系统以 RK3588（8 核 CPU、6 TOPS NPU）为唯一计算平台，采用“感知层—决策层—执行层”架构，搭载双通道麦克风阵列、USB 摄像头及三片 PCA9685 驱动的 29 路舵机阵列，构建多模态感知融合、端侧 AI 全栈部署、实时音唇同步的交互闭环。集成了 DOA 声源定位、sherpa-onnx 流式语音识别、自研心理垂域大模型“灵心 1.5B”（基于 Qwen2.5 在开源数据集全量微调，RKLLM 量化，NPU 推理）、Piper TTS 语音合成、UniTalk 音频驱动面部动画、RetinaFace 人脸检测、MobileNetV2 情绪识别及共情 Transformer 与 MLP 驱动舵机、PID 视觉追踪等技术。所有 AI 模型均在 RK3588 端侧本地运行，无需云端。

作品提出三项核心创新：一是自研心理垂域端侧大模型“灵心 1.5B”，赋予机器人情感理解与共情对话能力；二是自研轻量共情 Transformer 模型，实现符合社交预期的共情反馈而非简单情绪镜像；三是基于 UniTalk 与 MLP 分区域训练策略的音频驱动音唇同步技术，将 52 维 blendshape 系数高效映射为 29 路舵机角度；本作品聚焦心理开导与情感陪护场景，可广泛应用于居家养老情感陪伴、心理咨询辅助、特殊教育情感训练等领域。为低成本、高拟真的仿生人交互终端提供了一套完整的技术方案。

总之，本作品充分利用了 RK3588 的 NPU 与多核 CPU 算力，并且针对飞凌 ELF2 出厂内核未开启 USB Audio 驱动的问题，通过修改内核配置启用 USBAudio/MIDI 驱动以支持 8MICA 麦克风阵列的声源定位与语音拾取，同时二次开发 RKLLM 源码新增 llm\_demo\_v3.cpp，使微调的模型被注入 system prompt 与调整对话参数实现心理垂域对话的角色定制。最大限度发挥了端侧硬件的运算潜力。

## 第一部分 作品概述

### 1.1 功能与特性

本作品基于瑞芯微 RK3588 处理器，构建了一款具备多模态感知与实时交互能力的智能仿生人头系统。系统以语音交互为核心，融合声源定位、语音识别（ASR）、大语言模型对话（LLM）、语音合成（TTS）、音频驱动面部动画（Audio2Face）、视觉追踪、人脸识别、情绪识别、共情响应及 29 路舵机控制等技术，实现了从“听声辨位”到“察言观色”的完整人机交互闭环。

硬件以 RK3588 开发板为主控，搭载双通道麦克风阵列进行声源定位与语音拾取，USB 摄像头用于视觉感知，三片 PCA9685 舵机驱动板（I2C 总线 4、地址 0x40-0x42）控制共计 29 路舵机，实现面部表情与头部运动精确控制。其中 3 路颈部舵机独立大电压供电，PCA9685 仅提供信号；其余 26 路舵机由 PCA9685 直接驱动。系统配备 AEC 回声消除模块确保全双工通话质量。

软件方面，ASR 采用 sherpa-onnx 流式模型，LLM 部署“灵心 1.5B”心理垂域对话模型（RKLLM 量化，NPU 推理），TTS 采用 Piper 中文男声，面部动画通过 UniTalk+MLP 管线实现音频驱动音唇同步。视觉模块集成 RetinaFace 人脸关键点检测、人脸识别、MobileNetV2 情绪分类及 PID 追踪。多进程架构通过共享状态文件实现跨模块数据通信。




图 1 系统整体框架图

## 1.2 应用领域

本作品可广泛应用于以下场景：

**居家养老情感陪伴：**为独居老人提供全天候语音陪伴与情感慰藉。机器人具备共情对话能力和自然的面部表情，能感知老人情绪状态并主动关怀，有效缓解孤独感。

**心理咨询辅助：**作为心理咨询师的辅助工具，通过温和的语音对话引导用户表达情绪，结合面部表情识别与共情反馈，帮助用户缓解焦虑、释放压力。

**特殊教育情感训练：**应用于自闭症儿童社交训练，机器人通过可复现的面部表情和耐心的语音交互，帮助患者逐步建立社交认知与情感理解能力。

**科研教学平台：**作为多模态人机交互的开放实验平台，集成了语音处理、计算机视觉、自然语言处理、机械控制等多个领域算法，适合 AI 机器人相关课程的教学演示与算法验证。

## 1.3 主要技术特点

(1) 自研心理垂域端侧大模型：基于 Qwen2.5 1.5B 在开源心理咨询数据集上微调的"灵心 1.5B"对话模型，经 RKLLM W8A8\_128g 量化后部署于 RK3588 NPU，单独跑 LLM 推理速度约 70 tokens/s。结合视觉情绪识别结果动态注入共情提示词，实现具有情感感知能力的心理咨询对话。

(2) 音频驱动的实时音唇同步：采用 UniTalk 模型将语音波形直接映射为 52 维 ARKit blendshape 系数，经 MLP 分区域训练策略（上半脸+下半脸分别训练）高效转换为 29 路舵机角度，以 30fps 刷新率驱动舵机阵列，实现高拟真音唇同步效果。

(3) 多模态感知融合闭环：系统同时整合听觉（麦克风阵列声源定位+语音识别）和视觉（人脸检测/识别/情绪分析）两种感知通道，通过共享状态文件实现跨进程数据通信，使机器人能综合判断用户位置、身份和情绪状态，做出更自然的交互响应。

(4) 端侧 AI 全栈部署：ASR（sherpa-onnx）、LLM（灵心 1.5B RKLLM）、TTS（Piper）、人脸检测（RetinaFace RKNN）、人脸识别（ArcFace RKNN）、情绪分类（MobileNetV2 RKNN）、Audio2Face（UniTalk）等全部 AI 模型均在 RK3588 端侧本地运行，无需任何云端依赖。

#### 1.4 主要性能指标

| 性能指标     | 参数                                                                                            |
|----------|-----------------------------------------------------------------------------------------------|
| 处理器      | RK3588, 4×A76+4×A55, 8nm, 6 TOPS NPU                                                          |
| 语音识别     | sherpa-onnx transducer 14M, 中文实时转写, 端点检测                                                      |
| 大语言模型    | 灵心 1.5B (Qwen2.5 微调), RKLLM W8A8_128g, NPU ~10 tokens/s (只跑 LLM 时可以达到 60tokens/s, 只跑在四核 A7 上) |
| 语音合成     | Piper TTS, 中文男声, 22.05kHz, ~1.5 倍实时速率                                                         |
| 音唇同步     | TTS→UniTalk→52BS→MLP→29 舵机, 30fps 刷新, 端到端延迟<1s/句                                              |
| 人脸检测/识别  | RetinaFace @320×320 ~15fps / ArcFace @112×112                                                 |
| 声源定位     | 双通道 DOA, 80ms 分析窗口, 水平方向 ±90°                                                                 |
| 系统帧率     | 所有进程运行时的视觉 FPS, 预计 10FPS 左右 (只用四核 A55 跑视觉)                                                    |
| NPU 利用率  | 三核分别利用, 满频率运行 (跑视觉的三个 rknn 模型, 以及 LLM)                                                        |
| 启动到交互时间  | 脚本开始到模型全部预热完毕时间 (s)                                                                           |
| AEC 回声抑制 | ERLE, 预计可到 30dB                                                                               |

|          |                                        |
|----------|----------------------------------------|
| PID 视觉追踪 | 响应速度，平均多久锁定目标（s）                       |
| 功耗       | 满载功率（W）                                |
| 共情模型帧率   | 计算一次输入情绪识别输出的向量，输出 blendshape 系数的时间（s） |
| 运行内存     | GB                                     |
| CPU 温度   |                                        |

## 1.5 主要创新点

（1）自研心理垂域端侧大模型"灵心 1.5B"：基于 Qwen2.5 1.5B 在开源心理咨询数据集上微调，经 RKLLM 量化后在 RK3588 NPU 端侧推理，与视觉情绪识别联动实现共情对话。

（2）自研轻量共情 Transformer 模型：仅 140K 参数，7 类情绪 → TransformerEncoder → 19 模板权重合成，实现符合社交预期的共情反馈而非简单情绪镜像。

（2）基于 MLP 分区域训练策略的高效 Blendshape-舵机映射：将 UniTalk 输出的 52 维 blendshape 分上半脸、下半脸分别训练 MLP 网络，高效映射为 29 路舵机角度，兼顾精度与推理速度。

## 1.6 设计流程

遵循"需求分析→方案设计→硬件搭建→软件开发→系统集成→调试优化"全流程。需求分析以语音交互为核心、多模态感知为辅助。方案设计确定 RK3588 选型、Yundea 8MICA 麦克风阵列及 PCA9685 舵机驱动方案。硬件搭建完成 29 路舵机机械组装与布线；软件开发并行推进语音管线（ASR+LLM+TTS）、视觉管线（检测+识别+情绪）、表情控制（Audio2Face+舵机）三大子系统。系统集成通过共享状态文件连接各进程，随后完成 AEC 回声消除调优、PID 参数整定、音唇同步延迟优化等调试工作。

## 第二部分 系统组成及功能说明

### 2.1 整体介绍

本系统采用"感知层—决策层—执行层"三层架构，以瑞芯微 RK3588 为唯一核心计算平台。感知层负责采集外部环境信息，包括 Yundea 8MICA 双通道麦克



风阵列采集语音与声源方位、USB 摄像头采集视觉画面。决策层在 RK3588 上完成所有 AI 推理任务，包括 sherpa-onnx 语音识别、灵心 1.5B 大语言模型对话、Piper TTS 语音合成、UniTalk 音频驱动面部动画及 MLP 表情映射、RetinaFace 人脸检测与识别与锁定关键点、MobileNetV2 情绪分类及共情 Transformer 推理。执行层将决策结果转化为物理动作，通过三片 PCA9685（I2C 总线 4，地址 0x40-0x42）驱动 29 路 A0090 或 MG996R 舵机实现面部表情与头部运动控制。

各模块间通过共享状态文件实现跨进程数据通信：视觉进程写入情绪/人脸检测结果，语音进程读取后注入 LLM 对话 prompt；语音进程写入说话状态，视觉进程读取后控制打断逻辑，形成从“感知—决策—执行”的完整闭环。




图 2 系统整体流程图

## 2.2 硬件系统介绍

### 2.2.1 硬件整体介绍

系统硬件以 RK3588 核心板为主控，板载 8GB RAM、64GB eMMC 存储，搭载四核 Cortex-A76 + 四核 Cortex-A55 CPU 及 6 TOPS NPU，运行 Ubuntu 22.04 操作系统。所有 AI 推理任务均在本地完成，无需云端依赖。

麦克风阵列采用 Yundea 8MICA 双通道 MEMS 数字麦克风（FL/FR/FC/LFE 通道），采样率 48kHz，通过 USB 连接 RK3588，用于 DOA 声源定位与语音拾取。由于飞凌 ELF2 开发板的默认内核配置未包含 USB Audio/MIDI 驱动，导致

8MICA 麦克风阵列无法被系统识别。本作品参照官方文档，通过 `make menuconfig` 在 Device Drivers → Sound card support → ALSA → USB sound devices 中启用 USB Audio/MIDI driver，重新编译内核后设备被正确枚举。

视觉模块采用 USB 摄像头，采集视频帧送入 NPU 进行实时人脸检测、识别与情绪分析。舵机控制采用三片 PCA9685 PWM 驱动板通过 I2C 级联（总线 4，地址 0x40-0x42），每片输出 16 路 50Hz PWM 信号，共计 48 通道，实际使用 29 路驱动舵机。

电源方面，RK3588 核心板通过 USB-C PD 供电；3 路颈部舵机由独立大电压电源供电，PCA9685 仅提供控制信号；其余 26 路舵机由 PCA9685 直接驱动供电。系统配备 AEC 回声消除模块，确保全双工通话质量。HDMI 接口可连接显示器用于交互状态可视化。

本作品充分使用了 RK3588 的 NPU（3 个 RKNN 模型+1 个 RKLLM）、CPU（8 核多进程并行）、I2C（PCA9685 舵机控制）、USB（摄像头+麦克风阵列）、HDMI（UI 显示）、PulseAudio（音频处理）等片上资源。




图 3 硬件系统示意图

### 2.2.2 机械设计介绍

机械结构采用 3D 打印 PLA 骨架，包含头颅外壳、下颌开合机构、眼球转动机构、眉部抬升机构及脸颊牵引机构，共 29 个自由度。29 路舵机按功能分区布

局如下：眉毛左右各 2 路实现抬眉与皱眉；上下眼睑左右各 2 路控制睁眼闭眼；眼球左右各 2 路（水平与垂直）实现瞳孔转动；嘴唇及嘴角多路协同控制唇形变化；脸颊左右各 1 路配合嘴部动作；下颌左右各 2 路控制嘴巴开合；颈部含水平左右 2 路与垂直 1 路实现头部转动与点头（独立大电压供电）。舵机通过定制支架固定于 PLA 骨架，连杆与肌腱传动机构将舵机旋转运动转化为面部皮肤的局部位移，实现自然人脸表情的物理复现。定制的硅胶仿生面皮覆盖于机械骨架外层，口周、眼周等关键表情区域做减薄处理以增加运动幅度。




图 4 机械结构设计图

### 2.2.3 电路各模块介绍

电路系统以 RK3588 开发板为核心，通过 I2C 总线 4 连接三片 PCA9685 PWM 驱动板，地址分别为 0x40、0x41、0x42。每片 PCA9685 输出 16 路 50Hz PWM 信号，经排线连接至 29 路 MG996R 或 A0090 舵机。



信号流向如下：RK3588 的 I2C SDA/SCL 引脚（总线 4）→三片 PCA9685 的 SDA/SCL 输入级联→各 PCA9685 输出 PWM→对应舵机信号线。电源分配方面，3 路颈部舵机（通道 30-32）由独立大电压稳压模块供电，PCA9685 仅提供信号线直通；其余 26 路舵机由 PCA9685 板载电源端子供电。麦克风阵列与摄像头通过 USB 接口连接 RK3588，即插即用。




图 5 电路模块分布图

## 2.3 软件系统介绍

### 2.3.1 软件整体介绍

软件系统按功能划分为三个并行子系统：语音管线、视觉管线与表情控制管线。所有子系统在 RK3588 上以多进程架构运行，通过共享状态文件实现跨进程数据交互。

语音管线完成"语音采集→AEC 回声消除→ASR 语音识别→LLM 大语言模型推理→TTS 语音合成→扬声器播放"的全链路处理。ASR 采用 sherpa-onnx 流式 transducer 模型（14M 参数），支持中文实时转写与端点检测；LLM 部署经心理咨询数据微调的"灵心 1.5B"模型（RKLLM 格式，W8A8\_128g 量化，NPU 推理）；TTS 采用 Piper 中文男声模型在 CPU 上实时合成。

视觉管线完成"摄像头采集→RetinaFace 人脸与关键点检测→ArcFace 人脸识别→MobileNetV2 情绪分类→PID 舵机追踪"的视觉闭环。表情控制管线集成

UniTalk Audio2Face 模型（音频→52 维 ARKit blendshape）与 MLP 分区域映射网络（blendshape→29 路舵机角度），实现语音驱动自动音唇同步。




图 6 软件系统架构图

### 2.3.2 软件各模块介绍

#### （1）语音识别模块 — StreamingASR (asr\_engine.py)

采用 sherpa-onnx 流式 transducer 模型，接收 16kHz 单声道 PCM 音频，以 10ms 帧长滑动处理，实时输出中文文本，支持端点检测自动结束识别。

调度机制：主循环每 100ms 采集一次音频，每 2 帧（200ms）调用 `get_partial()` 获取中间结果用于 UI 显示；`is_endpoint()` 返回 True 时调用 `finalize()` 获取完整文本，送入文本队列供 LLM 消费。能量门控（`NOISE_GATE=0.008`）滤除底噪，播放时自动提高激活门限（`ENERGY_THRESHOLD_HIGH=200`）抑制 AEC 残留回声引起的误触发。




图 7 ASR 模块函数流程图

## (2) 大语言模型模块 — RKLLMClient (llm\_client.py)

"灵心 1.5B"以双核 NPU 模式运行 (RKNN\_NPU\_CORE=0,1)，基于 Qwen2.5 1.5B 在开源心理咨询数据集上微调，经 RKLLM W8A8\_128g 量化后部署。系统通过二次开发 RKLLM 官方 demo 源码得到 llm\_demo\_v3.cpp，新增命

令行 system

prompt 文件路径的功能，使"温暖专业的心理咨询师"角色设定与视觉情绪状（如 "[用户当前情绪: Happy(92%)]"）能被注入对话上下文。流式输出按句号/问号/感叹号切分为完整句，保证 TTS 处理与播放流水线重叠，仅第一句有初始延迟。




图 8 LLM 模块函数流程图

### (3) 语音合成模块 — PiperTTS (tts\_client.py)

采用 Piper TTS 中文男声模型 (zh\_CN-chaowen-medium)，将 LLM 输出文本合成为 22.05kHz 16 位 PCM 音频，在 CPU 上实时合成。

合成速度约 1.5 倍实时，每次调用返回完整音频字节流。音频同时作为 AEC 参考信号存入播放器的 ref\_deque 用于回声消除。




图 9 TTS 模块函数流程图

### (4) 音唇同步模块 — Audio2Face + MLP + SpeechPipeline

这是本作品表情控制的核心。TTS 合成的 WAV 音频文件送入 UniTalk 模型，模型将语音波形映射为 52 维 ARKit blendshape 系数序列。BS 序列经二阶低通滤波器（截止 4.0Hz）平滑后，送入上下脸 MLP 分别推理，合并为舵机角度指令以 30fps 同步播放。

分区域训练策略是本作品的特别贡献：上半脸 MLP（19 维 BS→8 路舵机 ID: 2,3,4,5,17,24,25,26）处理眉、眼高频微动；下半脸 MLP（32 维 BS→16 路舵机 ID: 0,1,7,8,9,13,14,15,16,18,19,20,21,22,28,29）处理嘴、颊、颌大幅动作。自监督 Motor Babbling 采集 7700 组配对数据，循环一致性训练（Cycle Loss + Supervised Loss + Smoothness Loss + Centering Loss + Boundary Loss + MMD Loss + Inverse Consistency）无需人工标注。MLP 输入前级 unitalk 输出的 BS 系数后会映射为舵机角度，让机器人音形和唇形一致。

**音唇同步函数流程图**




图 10 音唇同步函数流程图

### （5）音频采集与 AEC 模块 — audio\_io.py

音频采集与播放基于 PulseAudio 子系统，配备 WebRTC AEC 回声消除。

**AEC 工作流程：**PiperTTS 输出的音频在送入扬声器的同时，作为参考信号（重采样至 16kHz）存入 ref\_deque。麦克风采集的混合信号（用户语音+扬声器回声）与参考信号逐帧送入 WebRTC AEC，自适应滤波器估计回声路径并从混合信号中减除，ERLE 约 20dB。



AEC模块函数流程图




图 11 AEC 模块函数流程图

#### (6) 视觉追踪模块 — empathy\_track\_servo\_v3.py

采用 RetinaFace (MobileNet0.25 骨干, 输入 320×320, RKNN NPU 推理) 对摄像头每帧进行人脸检测, 输出边界框及 5 个关键点 (双眼、鼻尖、嘴角)。检测到的人脸区域经 MobileFaceNet (w600k\_mbf.rknn, RKNN NPU Core 2) 提取 512 维特征, 与注册人脸库余弦比对实现身份识别, 身份人的左眼相对画面中心的偏移量作为追踪误差, 经卡尔曼滤波平滑后输入 PID 控制器;

追踪策略: 小偏移优先调整眼部舵机 (通道 6,23) 实现精细跟随, 大偏移联合颈部舵机 (通道 30-32) 协同快速回正。8 像素死区避免微颤。目标丢失时触发"盲寻模式": 根据最后已知位置或声源定位结果发送扫描信号引导云台转动。




图 12 视觉追踪函数流程图

#### (7) 共情 Transformer 模块 — EmpathyModel (empathy\_model.py)

模块运行在 CPU 上 (PyTorch)，与上述三个 NPU 模型独立。它将视觉进程输出的 7 维情绪 softmax 序列 (来自 MobileNetV2 (emotion\_rknn, NPU Core 2 推理)) 作为输入，通过 TransformerEncoder + CrossAttention 生成 19 种表情模板的加权组合，输出 52 维 ARKit blendshape 系数。

这是本作品自研的情感响应核心。与简单镜像用户情绪的方案不同，共情模型通过 Transformer 架构理解情绪上下文，生成符合社交预期的复合表情。

核心设计理念是模型输出 19 种标准表情模板的加权组合 (如 "60% Happy + 30% Excitement + 10% Love")，而非直接输出 52 维 BS。解码矩阵 (19×52) 固定、不参与训练，确保输出始终在合理 BS 空间内。内置 LatentScheduler 周期性切换风格隐向量，确保同种情绪下的表情输出具有多样性，避免机械重复。典型映射：用户 Happy→"Happy+Excitement+Love" 分享愉悦；用户 Sad→"Trust+Loneliness" 给予陪伴；用户 Angry→"Neutral+Vigilance" 稳定情绪。

共情Transformer函数流程图




图 13 共情 Transformer 函数流程图


#### (8) 声源定位模块 — doa\_process.p

采用 TDOA 到达时间差算法，利用 8MICA 四通道麦克风的水平两通道进行互相关时延估计，驱动颈部舵机转向声源。系统以独立进程运行，使用 ALSA 直通 (arecord) 采集音频，通过 pactl suspend-source 临时挂起 PulseAudio 以避免与 ASR 音频管线冲突。采集的音频经降采样、Butterworth 带通滤波 (300-3400Hz) 保留人声频段后，执行 `scipy.signal.correlate` 互相关计算峰值延迟，换算为水平角度驱动舵机。

系统具备两种运行模式：独立模式 (`./run.sh doa`) 持续扫描声源，终端显示雷达界面，适用于调试演示；引导模式 (`--boot`，集成在 `./run.sh all` 中) 在系统启动时挂起 PA

接管声卡，持续监听直至检测到人脸后停止写舵机，经 3 秒静默让 PID 视觉追踪自然接管，随后恢复 PA 启动 ASR。

独立模式 / 引导模式 流程图



关键参数：帧长=40ms，阈值=400，滤波=300-3400Hz，舵机通道=32，确认帧数=8

图 14 声源定位函数流程图

### (9) 跨进程通信模块 — shared\_state.py

视觉进程与语音进程通过 JSON 文件实现跨进程数据共享，避免直接进程间同步的复杂性。

视觉进程写入：

```
write_vision_state(emotion, confidence, face_detected,
                  user_identity, face_box, face_center)
```

→ 写入 /tmp/morpheus\_vision.json

语音进程写入：

```
write_voice_state(speaking, status, user_text, bot_text)
```

→ 写入 /tmp/morpheus\_voice.json

读取接口：

```
read_vision_state() → dict
```

```
read_voice_state() → dict
```

```
get_emotion_prompt() → str
```

功能：读取视觉状态，若 face\_detected 且 confidence>0.3，

返回“[用户当前情绪：Happy (92%)]”格式字符串供 LLM 注入。这种设计确保了视觉进程崩溃时语音进程仍能继续运行（读到旧数据），反之亦然，提高了系统鲁棒性。UI 显示模块也通过此接口获取对话与情绪状态。




图 15 跨进程通信函数流程图

### 第三部分 完成情况及性能参数

#### 3.1 整体介绍

历经四个月的设计、编码与调试，本作品最终呈现为一个具备完整语音交互、视觉追踪、音唇同步与共情表达能力的仿生人头系统。当用户走近，它会主动转头跟随用户的目光，实现 eyes contact；当用户说话，它能听懂并回应，同时嘴唇随语音自然开合；当用户做出不同表情，它能识别情绪并以符合社交预期的方式共情反馈——这些不再是科幻场景，而是本作品已实现的真实功能。






图 16 整体成果正面图




图 17 整体成果斜 45° 图

以下从机械结构、电路系统、软件界面和特性展示四个方面，呈现最终成果。

### 3.2 工程成果（分硬件实物、软件界面等设计结果）

#### 3.2.1 机械成果



图 18 内部机械结构图




图 19 外部整体图

### 3.2.2 电路成果




图 20 电路成果图



### 3.2.3 软件成果




图 21 软件成果图

### 3.3 特性成果

#### (1) 音唇同步连续帧

在终端直接输入文本“你好，今天是星期四”，PiperTTS 将文本合成为音频，UniTalk 模型实时将音频映射为表情舵机的帧序列，驱动仿声人头部做出同步口型运动，同时通过 aplay 播放语音。录制仿声人面部录制整个发音过程，实验观察到 TTS 合成语音清晰自然，元音口型开合到位，辅音过渡平滑，口型与音频基本同步，截取发音过程中的三帧图像，分别对应“你”“好”“四”三个字的口型状态，如下图：




图 22 “你、好、四” 发音分别对应的口型

## (2) 情绪识别演示

在板子桌面终端运行 `run.sh`，DOA 声源唤醒后系统自动加载视觉追踪与语音交互管线。摄像头实时采集面部图像，RetinaFace 检测人脸区域，MobileFaceNet 提取面部特征并比对已注册人脸数据库进行身份识别，同时 Emotion RKNN 模型在 NPU 上推理七种基本表情（开心、悲伤、生气、惊讶、恐惧、厌恶、中性）的概率分布，共情模型结合表情识别结果与对话上下文生成情感状态和互动策略。对着镜头分别做出开心、悲伤的表情等，观察系统反应。结果显示：开心表情下系统识别准确，共情模块输出积极情感状态，回应语气愉悦；悲伤表情下系统自动切换为低沉柔和的交互语气。情绪状态的识别与共情反馈区分度明显，表情到回应的端到端延迟在可接受范围内，验证了情绪识别模块与共情策略的有效性。






图 23 识别“开心”情绪





图 24 识别“悲伤”情绪

系统主要性能实测数据如下图所示：



| 测试项目                | 单位              | 实测值                              |
|---------------------|-----------------|----------------------------------|
| LLM 推理速度            | tokens/s        | 10.2                             |
| 人脸检测帧率              | fps<br>@320×320 | 13                               |
| 音唇同步端到端延迟           | s/句             | 0.3                              |
| 共情 Transformer 推理速度 | fps @CPU        | 213.2                            |
| ASR 端点检测延迟          | ms              | 900                              |
| 系统冷启动时间             | s               | 13                               |
| AEC 回声测试            | ERLE            | 20dB                             |
| 功耗（开发板+舵机）          | W               | 39.96                            |
| 人脸识别                | 成功率与帧率          | 90% 13fps（与视觉系统帧率一致，每帧都检测）       |
| NPU 利用率             | MHz             | 1000（三核全部利用，跑视觉的三个 rknn 模型核 LLM） |
| 双通道声源定位准确率          | %               | 100                              |
| 视觉追踪平均响应时间          | s               | 1                                |
| 运行内存                | GB              | 4.6                              |
| CPU 温度              | 摄氏度             | 40                               |

## 第四部分 总结

### 4.1 可扩展之处

本作品在现有功能基础上仍有进一步扩展空间：（1）增加躯干与手臂自由度，使机器人具备肢体语言表达能力；（2）引入长期对话记忆机制，实现跨会话个性化陪伴；（3）优化 MLP 网络结构，探索更先进的例如 DiT 等模型架构；（4）增加无线通信模块，实现多台仿生人头的分布式协作交互。

### 4.2 心得体会

回顾整个研发过程，从方案论证到实物集成，每一步都充满了挑战与收获。

在方案设计阶段，如何在 RK3588 有限的硬件资源上同时运行 ASR、LLM、TTS、视觉追踪、Audio2Face 等多个 AI 任务是首要问题。经过多次论证，最终选择了多进程架构+共享状态文件的方案，将语音、视觉、表情控制分离为独立进程，充分利用 8 核 CPU 的并行优势。

LLM 的全量端侧部署是最大技术难点。要如何保证模型能力的情况下，尽量让模型轻量化，我们做了很多调整。同时将 1.5B 参数模型压缩部署到 NPU 上，经历了多次 RKLLM 转换失败和 NPU 推理崩溃，和其他视觉模型产生冲突，导致 NPU 带宽不够等问题。最终通过调整量化参数、使用双核 NPU（RKNN\_NPU\_CORE=0,1）、优化系统提示词等手段实现了稳定推理。

共情 Transformer 的设计经历了大量迭代。早期尝试直接映射用户情绪，效果生硬。受社交心理学启发，交互绝对不会死对你的表情模仿，而是能够读懂你的情绪，做出正确的回应，于是我们改为模拟交互模板权重合成方案——模型输出 19 种表情模板的加权组合，配合 LatentScheduler 保证多样性，实现了有温度的共情交互。

MLP 分区域训练策略源于对全脸联合训练困难的观察：上下半脸运动模式差异显著，眼眉以高频微动为主，嘴周以低频大幅动作为主。分开训练不仅解决了同步问题，还降低了推理计算量。自监督 Motor Babbling 数据采集方法使机器人能“自己动、自己看、自己学”，无需人工标注。

机械结构方面，29 路舵机的安装位置、连杆长度、硅胶面皮减薄厚度经过多版 3D 打印迭代。口周运动幅度与硅胶回弹力的平衡是最耗时的调试环节。

通过这个项目，我们深刻体会到嵌入式 AI 系统设计的核心原则：算法设计

与硬件约束必须从一开始就紧密耦合。在资源受限的端侧平台上，每一个算子的选择、每一次内存分配都需要精打细算。正是这些约束激发了我们在 MLP 分区域训练、跨进程通信、TTS，ASR 流式优化等方面的创新。当机器人第一次对我们说出带有情感温度的回应时，我们知道所有的努力都是值得的。

## 第五部分 参考文献

- [1] RK3588 Technical Reference Manual, Rockchip Electronics, 2023.
- [2] sherpa-onnx: Real-time Speech Recognition with Next-gen Kaldi, 2024.
- [3] Piper: A Fast, Local Neural Text-to-Speech System, Rhasspy, 2023.
- [4] Deng J, et al. ArcFace: Additive Angular Margin Loss for Deep Face Recognition. CVPR 2019.
- [5] Deng J, et al. RetinaFace: Single-shot Multi-level Face Localisation. CVPR 2020.
- [6] UniTalker: Audio-Driven Facial Animation. arXiv, 2024.
- [7] Howard A G, et al. MobileNets: Efficient CNNs for Mobile Vision Applications. arXiv, 2017.
- [8] RKLLM Toolkit User Guide, Rockchip Electronics, 2024.
- [9] Qwen2.5 Technical Report. arXiv, 2024.
- [10] Vaswani A, et al. Attention Is All You Need. NeurIPS 2017.
- [11] PCA9685 Datasheet, NXP Semiconductors.
- [12] WavLM: Large-Scale Self-Supervised Pre-Training for Speech Processing. arXiv, 2021.
- [13] Knapp C, Carter G. The Generalized Correlation Method for Estimation of Time Delay. IEEE T-ASSP, 1976.
- [14] SoulChat: Improving LLMs Empathy and Comfort Abilities. arXiv, 2023.
- [15] Chen Y, et al. Morpheus: A Neural-driven Animatronic Face. arXiv:2507.16645, 2025.